

**KARADENİZ TEKNİK ÜNİVERSİTESİ**  
**FEN BİLİMLERİ ENSTİTÜSÜ**

**BİLGİSAYAR MÜHENDİSLİĞİ ANABİLİM DALI**

**HİPERSPEKTRAL UYDU GÖRÜNTÜLERİNİN SINIFLANDIRILMASINDA**  
**VAE VE CNN İLE HİBRİT BİR YAKLAŞIM**

**YÜKSEK LİSANS SEMİNER ÇALIŞMASI RAPORU**

**Öğrencinin Adı Soyadı : Murat Can VARER**

**Öğrenci No : 379438**

**Danışman : Dr. Öğr. Üyesi Murat AYKUT**

**Seminer Sunum Tarihi : 21/ 01/ 2021**

## ÖNSÖZ

Bu çalışmada plevral efüzyon sitopatolojik görüntülerin derin öğrenme yöntemiyle otomatik algılanması sağlanmıştır. Veri tabanı hazırlama sürecinde ise görüntüler mikroskop-tan okunarak panorama yöntemiyle birleştirilmiştir ve bu görüntüden belirli boyutlarda görüntüler kesilerek hazırlanması sağlanmıştır. Bu çalışmada danışmanlığımı üstlenen değerli hocam Dr. Öğr. Üyesi Murat AYKUT'a ilgi, destek ve tecrübelerinden dolayı teşekkürü bir borç bilirim. Çalışmam boyunca bana her türlü desteği sağlayan yüksek lisans eğitimim boyunca sabır, destek ve sevgileriyle yanımda olan aileme ve dostlarıma çok teşekkür ederim.

Murat Can VARER

Trabzon 2021

## **TEZ ETİK BEYANNAMESİ**

Yüksek Lisans Tezi olarak sunduğum HİPERSPEKTRAL UYDU GÖRÜNTÜLERİNİN SINIFLANDIRILMASINDA VAE VE CNN İLE HİBRİT BİR YAKLAŞIM başlıklı bu çalışmayı baştan sona kadar danışmanım Dr. Öğr. Üyesi Murat AYKUT'un sorumluluğunda tamamladığımı, verileri/örnekleri kendim topladığımı, deneyleri/analizleri ilgili laboratuarlarda yaptığımı/yaptırdığımı, başka kaynaklardan aldığım bilgileri metinde ve kaynakçada eksiksiz olarak gösterdiğimi, çalışma sürecinde bilimsel araştırma ve etik kurallara uygun olarak davrandığımı ve aksinin ortaya çıkması durumunda her türlü yasal sonucu kabul ettiğimi beyan ederim. 28/05/2021

Murat Can VARER

## İÇİNDEKİLER

	<u>Sayfa No</u>
ÖNSÖZ .....	III
TEZ ETİK BEYANNAMESİ .....	IV
ÖZET .....	VI
SUMMARY .....	VII
ŞEKİLLER DİZİNİ .....	VIII
TABLolar DİZİNİ .....	IX
KISALTMALAR DİZİNİ .....	X
1. GENEL BİLGİLER .....	1
1.1. Giriş .....	1
1.2. Giriş 2 .....	3
2. Literatür Taraması .....	6
3. Kaynaklar .....	18

## YÜKSEK LİSANS TEZİ

### ÖZET

#### HİPERSPEKTRAL UYDU GÖRÜNTÜLERİNİN SINIFLANDIRILMASINDA VAE VE CNN İLE HİBRİT BİR YAKLAŞIM

Murat Can VARER

Karadeniz Teknik Üniversitesi  
Fen Bilimleri Enstitüsü  
Bilgisayar Mühendisliği Anabilim Dalı  
Danışman: Dr. Öğr. Üyesi Murat AYKUT

Yüksek hesaplamaların daha hızlı yapıldığı günümüz teknolojisinde artık işlem yükü fazla olan projeler daha kolaylıkla yapılmaktadır. Evrişimsel sinir ağları (ESA) (Convolution Neural Networks (CNN) ) görüntüler için sınıflandırma problemlerini çözmek amaçlı geliştirilmiş bir Derin öğrenme modelidir. Derin öğrenme, öğrenme düzeylerini temsil eden makine öğrenmesinin dalını ifade eder yani burada bahsi geçen derin kelimesi, sınıflandırılacak görüntülerin özelliklerini sinir ağı yapısının derinliğinden alır. Varyasyonel Oto-Kodlayıcı (VOK) (Variational AutoEncoder (VAE) ), temelde danışmansız öğrenme olarak kullanılan bir yöntemdir. Amaç görüntülerin boyutu küçültürken daha farklı görüntülerin elde edilmesi için gizli katman adı verilen alanda Gaussian gürültüsü uygulayarak temelde çeşitliliği arttırmaktır.

Uzaktan algılama, dünyanın yüzeyi hakkında bilgi edinme bilimidir. Günümüzde uzaktan algılama başta askeri hava sahası olmak üzere deprem hazırlığı aşamasında toplanma bölgelerinin de belirlenmesinde önemli rol oynamaktadır. Bu tez çalışmasında uydudan çekilmiş Hiperspektral Görüntüleri (Hyperspectral Images (HSI) ) CNN modelini kullanarak sınıflandırılması yapılacaktır.

**Anahtar Kelimeler:** Evrişimsel Sinir Ağları, Varyasyonel Oto-Kodlayıcı, Derin Öğrenme, Uzaktan Algılama

## MASTER THESIS

### SUMMARY

#### A HYBRID APPROACH TO THE CLASSIFICATION OF HYPERSPECTRAL SATELLITE IMAGES VAE AND CNN

Murat Can VARER

Karadeniz Technical University  
The Graduate School of Natural and Applied Sciences  
Computer Engineering Graduate Program  
Supervisor: Asst. Prof. Murat AYKUT

In today's technology, where high calculations are made faster, projects with high processing load can be done more easily. Convolutional neural networks (ESA) (Convolution Neural Networks (CNN)) is a Deep learning model developed to solve classification problems for images. Deep learning refers to the branch of machine learning that represents levels of learning, so the word deep referred to here derives the properties of the images to be classified from the depth of the neural network structure. The Variational AutoEncoder (VAE) is basically a method used as unsolicited learning. The aim is to increase the variety by applying Gaussian noise in the area called the hidden layer in order to obtain more different images by reducing the size of the images.

Remote sensing is the science of obtaining information about the earth's surface. Nowadays, remote sensing plays an important role in determining the gathering areas during the earthquake preparation phase, especially in military airspace. In this thesis, Hyperspectral Images (HSI) taken from satellite will be classified using CNN model.

**Key Words:** Convolution Neural Networks, Variational AutoEncoder, Deep Learning,  
Remote Sensing

## ŞEKİLLER DİZİNİ

	<u>Sayfa No</u>
Şekil 1.1 Uzaktan algılamada rastgele bölünmelerin kullanıldığını gösteren elektromanyetik spektrum. ....	2
Şekil 1.2 Tipik bir uzaktan algılama sisteminin enerji yolları ve bileşenleri. ....	3
Şekil 1.3 Hiperspektral görüntü kavramı. Görüntü ölçümleri birçok dar bantlı dalga boyu bandında yapılır ve her piksel için eksiksiz bir spektrum elde edilir. Shippert, 2003 .....	4

## TABLÖLAR DİZİNİ

	<u>Sayfa No</u>
Tablo 2.1 Çalışmaların kısa açıklaması .....	11
Tablo 2.2 Pavia Üniversitesi için sonuçlar .....	16
Tablo 2.3 India Pines için sonuçlar .....	17
Tablo 2.4 Salians için sonuçlar .....	17



## KISALTMALAR DİZİNİ

CAD	Bilgisayar-Destekli tanı (Computer-Aided Diagnosis)
FAST	Hızlandırılmış Segment Testinden Öznitelikler (Features From Accelerated Segment Test)
RANSAC	Rastgele Örnek Onaylaşımı (Random Sample Consensus)

## 1. GENEL BİLGİLER


Bu başık altında Uzaktan Algılama (Remote Sensing- RS) nın tanımı ve kullanım alanlarından bahsedilecek. Bununla birlikte Hiperspektral Görüntüleme (Hyperspectral Imaging- HSI) hakkında genel bilgiler verilecek. Geçmişten günümüze teknolojik olarak ilerlemesinde bahsedildikten sonra Evrişim Sinir Ağı (Convolution Neural Network- CNN) temel yapısı anlatılacak. Hangi amaçla geliştirildi nerelerde daha çok tercih ediliyor. Geliştirdiğimiz modelde kullandığımız Varyasyonel Oto-Kodlayıcı (Variational Autoencoder- VAE) çalışma şekli anlatılacaktır.

(Eismann, 2012) bir yazarlı (Lu ve Fei, 2014) iki yazarlı (Lowe, Harrison, ve French, 2017) üç yazarlı (Lowe vd., 2017) üç yazarlı

### 1.1. Giriş

Uzaktan algılama, nesnelerden yansıyan veya yayılan radyasyona dayalı olarak Dünya yüzeyinde veya yakınında bulunan nesneler ve atmosfer hakkında bilgi sağlar. Bilgiler genellikle belli bir mesafede yakalanır ve veriler görüntü biçimindedir. Bu tür veriler, Dünya yüzeyinin ve atmosferinin bileşimini ve doğasını yerelden küresel ölçeklere kadar belirlememizi ve farklı noktalarda yakalanan görüntüleri analiz ederek değişiklikleri değerlendirmemizi sağlar. Bu anlamda, uzaktan algılama, başka türlü elde edilmesi zor veya imkansız olan uzamsal bilgilerin sağlanmasında yararlıdır. Sosyal bilimlerde uzaktan algılama, insan ortamlarını görselleştirmek (alternatif ve sinoptik görüşler sağlamak) ve sınıflandırmak için kullanışlıdır. Sosyal bilim araştırmacıları, uzamsal analizler yapmak için genellikle uzaktan algılanan verileri veya türevlerini Coğrafi Bilgi Sistemleri (Geographic Information Systems- GIS) içindeki diğer sosyoekonomik veri setleriyle entegre eder. Dünyanın yüzeyi, uzaktan algılamanın temelini temsil eder. Uzaktan algılamada, radyasyon tipik olarak ölçülür ve logaritmik bir ölçek kullanılarak dalga boyuna göre kategorize edilir. Dalgaboyu aralığı elektromanyetik spektrum olarak bilinir (Şekil 1.1) Read ve Torrado, 2009.


Uzaktan algılamanın çalışma aşamasını anlatacaklar olursak ilk olarak bir çok bileşenlerini açıklamamız gerekir. Bunlar Enerji, Elektromanyetik Radyasyon, Uydu sensörleri olarak



Şekil 1.1: Uzaktan algılamada rastgele bölünmelerin kullanıldığını gösteren elektromanyetik spektrum.

söyleyebiliriz. Enerji, hem içinden geçtiği atmosferle hem de algılanan Dünya yüzeyiyle etkileşime girer. Elektromanyetik radyasyon atmosferden geçerken dağılır, emilir ve kırılır. Uydu sensörleri için, ışık atmosferde uzun mesafeler kat etmelidir ve yansıyan ışık durumunda, atmosferde iki kez (Güneş'ten Dünya'nın yüzeyine ve Dünya'nın yüzeyinden sensöre) gitmelidir (Şekil 1.2). Işığın saçılması ve emilmesinden kaynaklanan bazı önemli atmosferik etkiler

dalga boyuna bağlıdır ve belirli bir dalga boyunun ne kadar enerjisinin atmosferden geçip sensöre ulaşabileceğini belirler. Örneğin, daha kısa dalga boyları, atmosfer tarafından daha uzun dalga boylarından daha fazla dağılma eğilimindedir ve sonuç olarak pus ve bulutlardan daha fazla etkilenir Read ve Torrado, 2009.



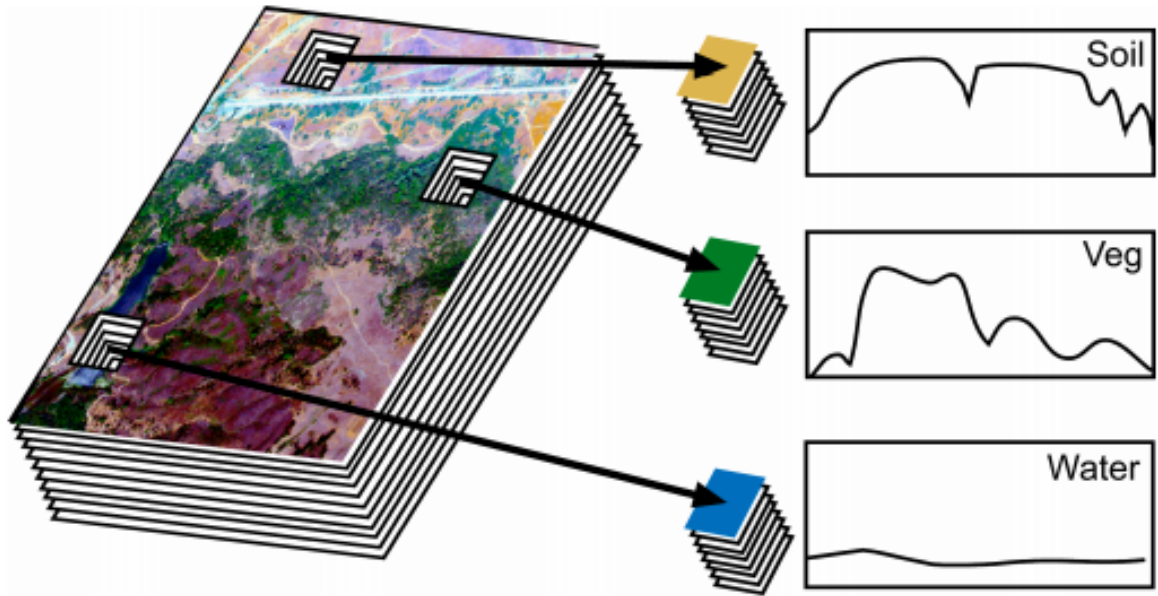
Şekil 1.2: Tipik bir uzaktan algılama sisteminin enerji yolları ve bileşenleri.

Son birkaç on yılda, Hiperspektral Görüntüleme (HSI) önem kazanmış ve görsel veri analizinin birçok alanında merkezi bir rol oynamıştır. Görüntüleme ile birleştirilen spektroskopi kavramı ilk olarak 1970'lerin sonunda Uzaktan Algılama (RS) alanında Goetz vd., 1985 kullanılmaya başlandı. O zamandan beri HSI, çeşitli özel görevler için artan sayıda alanda uygulamalar bulmuştur ve günümüzde RS Eismann, 2012 dışında, biyotıp Lu ve Fei, 2014, gıda kalitesi Sun, 2010, tarla yetiştiriciliği Kamilaris ve Prenafeta-Boldú, 2018; Lowe vd., 2017 ve kültürel miras Fischer ve Kakoulli, 2006 ve diğerleri Khan vd., 2018 dışında büyük ölçüde kullanılmaktadır.

## 1.2. Giriş 2

Hiperspektral görüntü küpleri, farklı elektromanyetik spektrumlardan (spektral bantlardan) alınan yüzlerce veya binlerce uzamsal görüntüden oluşur. Bu nedenle, araştırma

yapanlara aynı anda hem uzamsal hem de spektral bilgi sunarlar. Hiperspektral görüntüler, sahnenin spektral özelliklerini gözlemlemeye yardımcı olan yüzlerce spektral bant (kızılötesi (IR) elektromanyetik spektrum bandında, 0,4-2,4  $\mu\text{m}$ ) içerir. "Hiper-" ön eki, çok sayıda (100'den fazla) dar spektral bant (10-20 nm genişliğinde) içermekten gelir. Bu spektral bantlardaki güneş enerjisi, dünya nesneleri tarafından yansıtılır ve yansıtma değeri, malzemeleri ayırt etmek için kullanılır. Hiperspektral görüntüler, Şekil 1.3'de gösterildiği gibi üç boyutlu veri küpleri (hiper küp) olarak gösterilebilir. Hiper küp, pikseller dahil uzamsal verileri içerir. Ve her pikselin spektral bilgisi vardır L. Ma vd., 2010. Hiperspektral görüntülemeye teknolojinin gelişmesiyle birçok ülke bu alana odaklanmıştır. Örneğin, Almanya'nın Environmental



Şekil 1.3: Hiperspektral görüntü kavramı. Görüntü ölçümleri birçok dar bitişik dalga boyu bandında yapılır ve her piksel için eksiksiz bir spektrum elde edilir. Shippert, 2003

Mapping and Analysis Programı (EnMAP), Dünya'nın çevresini küresel ölçekte izlemeyi ve nitelendirmeyi hedeflemektedir. Bu durum günden güne uzaktan algılama görüntülerindeki artışa paralel olarak hiperspektral veri ambarlarında artışa neden olmaktadır. Bunun sonucunda da, görüntülerdeki gizli bilgilerin açığa çıkarılabilmesine imkân tanınmaktadır. Ancak, bu bilgilerin nasıl kullanılacağı daha fazla araştırma gerektiren açık bir konudur.

Özellikle, Evrişimli Sinir Ağları (Convolutional Neural Networks = CNN) LeCun vd., 1999 birçok bilgisayarlı görme problemi için güçlü bir araçtır. Diğer derin öğrenme algoritmalarından farklı olarak, CNN'ler, katlama – evrişim- (filtreleme) işleminin görüntünün belirli bir alıcı alanı (receptive field) üzerinde gerçekleştirildiği evrişim katmanlarını içerir.

Derin Öğrenme mimarileri uzaktan algılamada birçok amaç için kullanılabilir: görüntü ön işleme, piksel tabanlı sınıflandırma, hedef tanıma, anlamsal özellik çıkarma ve sahne anlamlandırma.

Derin Öğrenmenin uzaktan algılama verilerinde kullanımı bazı nedenlerden dolayı ekstra motivasyona sahiptir:

1. Uzaktan algılama verileri (özellikle çok bantlı ve hiperspektral görüntüler), çoklu spektral bantlar içerir. Bu, birkaç görüntüde bile veri miktarının çok büyük olduğu anlamına gelir. Bu yüzden daha fazla nörona ve daha derin sinir ağlarına ihtiyaç duymaktadır [4].
2. Uzaktan algılama görüntüleri, doğal sahne görüntülerinden daha karmaşıktır. Farklı renk, konum, boyut ve yönelime sahip çeşitli nesne türlerinden oluşabilir. Bu karmaşıklık, doğal (natural) görüntü tanıma için ortak bir yaklaşım olan transfer öğrenmenin başarılı bir şekilde uygulanmasına engel olur. Transfer öğrenmede, derin öğrenme modeli çok sayıda etiketli numuneye sahip olan bir veri seti ile (ImageNet gibi) ön eğitimden geçirilmiştir. Ardından, sınırlı eğitim numuneleriyle sadece modelin son 2 veya 3 tam bağlı katmanını yeniden eğitilerek (önceki katmanlar değil) model parametreleri (ağırlıklar) güncellenir. Ayrıca, görsel farklılıklara neden olan farklı sensörlerle görüntüler çekilebilir.
3. Her ne kadar derin öğrenme yöntemleri çok sayıda etiketlenmiş veri ile mükemmel bir performans sergilese de, uzaktan algılamada yalnızca sınırlı sayıda etiketli veri bulunmaktadır. Bu durum derin öğrenme yöntemlerinin performansını sınırlamaktadır

Yukarıda belirtilen nedenlerden ötürü, hiperspektral uzaktan algılama için en uygun derin sinir ağı mimarisinin geliştirilmesi zorlayıcı ve popüler bir araştırma alanıdır.

## 2. Literatür Taraması

Son yıllarda veri toplama / erişimin kolaylaşması ve bilgisayarların hesaplama gücünün artması nedeniyle derin mimariler son yıllarda makine öğrenimi alanında kullanışlı ve popüler hale geldi. Ve derin yöntemler, sahne etiketleme (Farabet vd., 2012), rakam sınıflandırması (Sermanet vd., 2012), karakter sınıflandırması (Ciresan vd., 2011), yüz tanıma (Lawrence vd., 1997), doğal dil işleme (Kalchbrenner vd., 2014) gibi birçok sınıflandırma alanında etkinliğini kanıtlamıştır. Bu alanların yanı sıra, uzaktan algılama alanı, özellik çıkarma ve sınıflandırma için derin yöntemlerin etkinliğini de kullandı. Bu bölümde, hiperspektral görüntü sınıflandırması için derin mimariler öneren çalışmalar tartışılacaktır.

(Hu vd., 2015) 'de, özellikleri çıkarmak ve verileri sınıflandırmak için 5 katmanlı bir CNN benimsenmiştir. Yapıdaki katmanlar sırasıyla girdi, evrişim, maksimum havuzlama, tam bağlantılı ve çıktı katmanlarıdır. Bu basit yapı, birçok evrişimli katmana sahip tipik ESA'lar hiperspektral veriler için geçerli olmadığından benimsenmiştir.

(Yue, Zhao, vd., 2015) 'de, hiperspektral görüntü sınıflandırması için ortak bir spektral-uzaysal çerçeve önerilmiştir. Bu makalede, boyut küçültme amacıyla temel bileşen analiz (PCA) kullanılmıştır. Görüntünün PCA'sı çıkarılır ve CNN'e beslenir. PCA yardımıyla, 103 kanaldan komşu bölgenin boyutu ve piksel cinsinden spektral özellik haritası 42x42'e dönüştürülür. Derin ESA yapısı 3 evrişimli ve 2 alt örnekleme katmanından oluşur. Spektral özellik 7 haritası, spektral vektörün 42 altvektöre bölünmesi ve her bir alt vektörün nokta çarpımının karekökü alınmasıyla oluşturulur. Sınıflandırma aşamasında LR seçilir.

(S. Li vd., 2019) 'da, ilk olarak görüntüyü parçalara bölme işlemi yapıldı ve daha sonra merkez-komşuluk spectrum çiftleri oluşturulmuştur. Bu işlem adımlarından sonra vektör olarak çıkan sonuçlar 2B olarak birleştirdi. Daha sonra bunları ESA ve SAE(Stack Autoencoder) ile birlikte kullanıldı. ESA işleminden sonra softmax normalizasyon ile ağırlık öğrenme ağı oluşturmuş. Daha sonra öğrenilen her bir ağırlığın özelliğini çıkarıp bunları stack autoencoder a verildi. Bu işlemin sonunda çıktıyı MLR( multinomial logistic regression) katmanına aktarıp sınıflandırmayı bu aşamada yapmıştır.

(Zhao, Z. Guo, vd., 2015)'de, derin özellikleri çıkarmak için çok ölçekli bir evrişimli otomatik kodlayıcı (MCAE) geliştirilmiştir. Yapı 2 ana bileşene ayrılmıştır: özellik çıkarma

ve sınıflandırma. İlk adımda, 2 tür özellik çıkarılır: spektral ve MCAE özellikleri. Spektral özellikler, PCA uygulanarak ve 3 temel bileşen (PC) alınarak elde edilir. Spektral özellikler elde edildikten sonra MCAE işlemi uygulanır. 3 için Her bir PC'ye karşılık gelen görüntüler, piramit havuzlaması, görüntülerin 3 ölçekte altörneklenmesi ile uygulanır. Ortaya çıkan görüntüler normalleştirilir ve ardından CNN'de eğitilir. CNN, filtre boyutu  $7 * 7$  olan 2 katmandan oluşur. Sigmoid fonksiyonları ve  $2 * 2$  max havuzlama işlemleri her katmana uygulanır. Çıktıda 315 özellik haritası elde edildi. Bu, her piksel için 315 boyuta karşılık gelir. Daha sonra, bu özellikleri kullanarak her numuneyi etiketlemek için bir lojistik regresyon sınıflandırıcı kullanılır.

(Y. Liu vd., 2015)' de, verilerin spektral özellik temsillerini öğrenmek için yığılmış denoising otomatik kodlayıcılara (SDA) dayalı derin bir model tanıtıldı. Ayrıca, spektral sınıflandırma sonuçlarının iyileştirilmesi için uzamsal kısıtlamaları oluşturmak için süper pikseller konuşlandırılır. SDA'nın yapısı 5 katmandan oluşur: bir giriş katmanı, 3 gizli SDA katmanı ve bir çıkış katmanı. Pikseller, giriş katmanı olarak doğrudan ağa beslenir. Ardından, ağın çıkışına PCA uygulanır. Lab renk uzayını temel bileşenlerle değiştirdikten sonra, SLIC algoritması kullanılarak süper pikseller oluşturulur. Her süper pikselin sınırındaki pikseller için, sınıflandırma ayrı ayrı yapılır. Son olarak, sınıf etiketleri her süper pikselde çoğunluk oyuyla atanır.

(Zhao ve Du, 2016)' de, boyut azaltma için dengeli yerel ayırıcı gömme (BLDE) algoritması ile derin bir CNN modeli önerilmiştir. Hiperspektral örnekler, farklı sınıflar arasında sınıf içi varyasyon ve benzerlik gösterdiğinden, boyut azaltma yönteminin seçimi, sınıflandırma başarısında hayati bir role sahiptir. Her bir sınıfı ayırmayı amaçladıkları için denetimli boyut küçültme (DR) yöntemlerinin denetimsiz yöntemlere göre daha başarılı olduğu bilinmektedir. BLDE algoritması, farklı sınıflar arasındaki yerel marjı eşzamanlı olarak maksimize eden doğrusal bir eşlemeyi tahmin eder ve sınıf içinde numunelerin yakın kalmasını sağlar. Öte yandan, CNN, uzamsal ilişkili derin özellikleri çıkarmak için uygulanır. CNN'i uygulamadan önce, giriş verilerinin temel bileşenleri PCA kullanılarak çekildi. Ardından, BLDE tabanlı özellikler CNN tabanlı özelliklerle istiflenir ve bir LR sınıflandırıcısına beslenir. Yöntem, Pavia Center ve Pavia Üniversitesi veri kümelerinde test edildi. DR işlemi önemli miktarda zaman alsa da, sonuçlar tatmin edicidir.

(A. J. Guo ve Zhu, 2018)' de, yapay sinir ağı tabanlı bir çerçeve tanıtıldı. Bu makalede, derin özelliklerin ayrılabilirliğini artırmak için merkez kaybı parametresi oluşturulmuştur. Bu



amaçla, her bir giriş özelliği ile her bir sınıfın karşılık gelen merkezi arasındaki mesafelerin ortalaması alınarak elde edilir. Her sınıfın merkezi, ilgili sınıfın özelliklerinin ortalaması alınarak belirlenir. Önerilen mimarinin kayıp fonksiyonu, softmax kaybına merkez kaybı eklenerek hesaplanır. Bu makalenin bir başka katkısı, belirli bir örneğe en yakın sınıf merkezine göre etiket atayan merkez sınıflandırıcı yaklaşımıdır. Yama tabanlı örnekler kullanılarak eğitilen diğer modellerden farklı olarak, bu yöntem eğitim aşamasında yalnızca spektral özellikleri besler. Test aşamasında mahalle alanı dikkate alınır. Verilen örneğin her bir sınıf merkezine uzaklığı 8 mahalle ölçeği (3x3, 5x5, ..., 17x17) için hesaplanmıştır. Aynı etikete sahip mahalleler toplandıktan sonra her sınıfın ağırlığı hesaplanır ve en fazla ağırlık ile örnek sınıfa atanır.

(Chen vd., 2018)' de, ilk olarak uzaysal alandaki yerel benzerliği göz önünde bulundurarak, hiperspektral görüntüden görüntü blokları elde etmek için büyük bir uzaysal pencere kullanıldı. İkinci olarak, görüntü bloğunun her bir spektral kanalı, uzaysal ve spektral özelliklerini çıkarmak için filtrelendir, bundan sonra özellikler evrişimli katmanlarla birleştirildi. Son olarak, sınıflandırma sonucunu elde etmek için tamamen bağlantılı katmanlar kullanılır. Ek olarak, hiperspektral görüntü sınıflandırmasının performansını artırmak için önerilen ağı geleneksel destek vektör makinesi (SVM) sınıflandırıcı ile birleştirir. Ayrıca, bu yazıda uzamsal pencere boyutları seçiminin uyarlanabilir bir yöntemi önerilmektedir.

(Paoletti vd., 2018)' de, spektral-uzaysal bilgileri kullanan 5 katmanlı bir CNN modeli tanıtıldı. 3B çekirdekler, ayırt edici özellikler elde etmek için evrişimli katmanlara uygulanır. Örneği daha iyi tanımladığına inanarak 9, 19 ve 29 gibi çok büyük yama boyutları benimsenmiştir. Deneyler sırasında algoritma, 9x9 mahalle çıkarıldığında 1500 iterasyonla sınıflandırma hatasına ulaşırken, 19x19 pencere boyutunda aynı hata değerine ulaşmak için 1000 iterasyon gerekir. Görüntü  $n \times n$  parçaya bölünürken, sınırların etrafındaki pikseller ayıklanamaz. Bu algoritma, aynalama ile kenar piksellerini kopyalar ve bu pikselleri sınıflandırmaya dahil eder. Testler sırasında etkisini gözlemlemek için çeşitli eğitim örnekleri (50, 100 ve 200) kullanılır. En iyi sonuçlar 200 eğitim örneği ve 29x29 yama ile elde edilir.

(Yue, Mao, vd., 2016)' de, uzamsal ve spektral özelliklerin SAE ve CNN aracılığıyla ve ardından bir LR sınıflandırıcı yoluyla birleştirilmesi için bir motor görevi görür. SAE, verilerin boyutunu küçülterek üst düzey özellikler elde edilmesi hedeflenmektedir. Geleneksel CNN, nesnelerin ölçek varyansına tolerans göstermediğinden, SPP ilk kez hiperspektral görüntü sınıflandırmasına, üst evrişimli katmanların uzamsal özellik haritalarını sabit

uzunlukta bir özelliğe havuzlayarak tanıtıldı. Algoritma 4 adım içerir: SAE aracılığıyla derin spektral özelliklerin oluşturulması, bir CNN modelinin eğitilmesi ve üst evrişimli katmanların havuzlanması, spektral-uzamsal özellik ayarlama parametresinin belirlenmesi ve LR sınıflandırıcısını beslemek için spektral-uzamsal özelliklerin birleştirilmesi. Ayarlama parametresi deneylerle belirlenir ve özelliklerin ağırlık oranını düzenler.

(Zhong vd., 2017)' de, hiperspektral görüntü sınıflandırması için özellik mühendisliği olmaksızın girdi verileri olarak ham 3-D küpleri alan uçtan-uca spektral-uzamsal artık ağ (SSRN). Bu ağda, spektral ve uzamsal kalıntı bloklar art arda hiperspektral görüntüleme (HSI) bol spektral imzalardan ve uzamsal bağlamlardan ayırt edici özellikleri öğrenir. Önerilen SSRN, diğer derin öğrenme modellerinin azalan doğruluk fenomenini hafifleten deneysel bir derin öğrenme çerçevesidir. Spesifik olarak, artık bloklar, gradyanların geri yayılmasını kolaylaştıran kimlik eşleme yoluyla diğer her 3-D evrişimli katmanı birbirine bağlar. Ayrıca, öğrenme sürecini düzenlemek ve eğitilmiş modellerin sınıflandırma performansını iyileştirmek için her evrişimli katmana toplu normalleştirme uygularız.

(Roy vd., 2019) 'de, HSI sınıflandırması için bir Hibrit Spektral Evrişimli Sinir Ağı (HybridSN) önermektedir. Temel olarak, HybridSN, bir spektral-uzamsal 3D-CNN ve ardından uzamsal 2D-CNN'dir. 3D-CNN, bir dizi spektral banttan ortak uzaysal-spektral özellik temsili kolaylaştırır. 3D-CNN'nin üstündeki 2D-CNN, daha fazla soyut düzeyde mekansal temsili öğrenir. Dahası, hibrit CNN'lerin kullanımı, tek başına 3D-CNN ile karşılaştırıldığında modelin karmaşıklığını azaltır.

(Bai vd., 2019) < < Eklenecek > >

(Mirzaei, Khosravani, vd., 2019) 'de ,3 Boyutlu Evrişimli Sinir Ağı (CNN) kullanarak hiperspektral görüntü sınıflandırma görevini ele alınmıştır. Yaygın olarak kullanılan ham spektral özellikler yerine, hiperspektral verileri Negatif Olmayan Tensör Çarpanlarına Ayırma (NTF) ile çarpanlara ayırarak ayırt edici özellikler elde edilir. Faktörler, son üyelerin spektral imza matrisinin yanı sıra bolluk matrisinden oluşur. Elde edilen bolluk haritaları, görüntünün uzamsal-spektral özelliklerini temsil eden özellik vektörlerini çıkarmak için kullanılır. piksellerin spektrumları veri matrisinin sütunlarında yığılır, uzamsal bilgiler NTF ile korunur. Morfolojik öznitelik filtreleri ayrıca çıkarılan bolluk haritalarına uygulanır ve bir 3D CNN'ye beslenen ayırt edici eğitim özelliklerini oluşturur. Görüntü sınıflandırması için bir 3D CNN çerçevesi. Ortak uzay-spektral özellikleri ve parametre paylaşımını kullanan bir 3D CNN, umut verici sınıflar sağlar. sınıflandırma performansı. Ayrıca sonuçları bir SVM

sınıflandırıcıyla karşılaştırarak önerilen CNN'nin etkinliğini de göstermiştir.

(He vd., 2019) 'de , ilk hyperspectral görüntülerden tek tek pikselleri alıyor. Bu işlem için flat diye bir yöntem uyguluyor. Burada bahsedilen flat işlemi bu piksellerin birleştirmesini ifade ediyor. Sonra çıkardığı her bir pikselleri başka bir yöntem olan pixel gömme olarak birleştiriyor. Sonra BERT ismi verilen bir sıralı ağa veriyor. Bu işlemin ardından çıktıları tam-bağlı ağa verip burada eğittikten sonra sınıflandırma işlemi yapılmıştır.

Tablo 2.1: Çalışmaların kısa açıklaması

İndeks	Yöntem	Yıl	Önerilen Yeni Yöntem	Boyut Azaltma	Yaklaşım
(Hu vd., 2015)	ESA	2015	1 katmanlı evrişim ile basit bir ESA	-	Danışmanlı
(Yue, Zhao, vd., 2015)	ESA	2015	verileri 42 alt vektöre bölmek ve her bir alt vektörün iç çarpımını almak	PCA	Danışmanlı
(S. Li vd., 2019)	ESA	2019	verileri 7x7 alt vektörlere bölüp spektrumların yakın komşuluklarını ESA ve ardında SAE birlikte	PCA	Danışmanlı
(He vd., 2019)	ANN	2020	görüntüdeki pikselleri tek bir boruya aktarıp daha çift yönlü trafo (BERT) ile kullanımı	-	Danışmanlı
(Roy vd., 2019)	ESA	2020	3B-ESA ve ardından 2B-ESA ile sınıflandırma işlemi	PCA	Danışmanlı
(Jiang vd., 2019)	ESA	2019	3B-ESA ve Transfer Learning	-	Danışmanlı

(Jiang vd., 2019) 'de, iki aşamalı bir modeldir. İlk aşamada samples extractions , yani örneklerden özellik çıkarma işlemi yapılıyor. Sonra 3B-SRNet ağı ile özellik çıkarımı ve sınıflandırma işlemi yapılıyor.

(Q. Gao ve Lim, 2019)'de, ilk olarak, temsili özelliklerin çıkarılması için iki evrişimli sinir ağı (CNN'ler) geliştirildi. Özellikle, piksel bazlı bir CNN ve yama bazlı bir CNN, özellikle spektral özellikleri ve spektral-uzamsal özellikleri çıkarmak için tasarlandı. İki sinir ağı, çeşitli evrişimli, havuzlama ve etkinleştirme katmanlarından oluşur ve test piksellerinin sınıf üyelik olasılıklarını tahmin edebilir. İkinci olarak, olasılıksal sonuçları Bayesci bir perspektiften rafine etmek için iki olasılıklı gevşeme yöntemi, yani Markov rasgele alanları ve gevşemeyi koruyan süreksizlik, çerçeveye entegre edildi. Spektral alanda piksel bazlı bir olasılıklı CNN oluşturulur ve hem spektral hem de uzamsal alanlarda yama bazlı bir olasılıklı CNN oluşturulur. Olasılıksal gevşeme, MRF, sırasıyla spektral ve uzaysal enerjiyi temsil eden iki terim içeren bir enerji fonksiyonunun bir minimizasyonu olarak formüle edilmiştir. Herhangi bir PR metodu içermeyen piksel bazlı CNN (pwCNN olarak anılır) ve herhangi bir PR metodu içermeyen 3D yama bazlı CNN (pbCNN olarak anılır), kıyaslama sınıflandırıcıları olarak kullanıldı.

(C. Wang vd., 2019) < < Eklenecek > >

(H. Gao vd., 2019)' de, HSI sınıflandırması için yeni bir uçtan-uca aktivasyon öncesi artık dikkat ağı (PRAN) önermektedir. Ön aktivasyon mekanizması ve dikkat mekanizması, önerilen ağa dahil edilir ve önerilen ağın, kanal yanıtlarının yeniden kalibrasyon özelliğini

uyarlamalı olarak taşımasına ve daha sağlam spektral-mekansal eklem öğrenmesine olanak tanıyan bir ön aktivasyon artık dikkat bloğu (PRAB) tasarlanmıştır. özellik gösterimleri. Önerilen PRAN, iki PRAB ve farklı çekirdek boyutlarına sahip birkaç evrişimli katmanla donatılmıştır, bu da PRAN'ın yüksek düzeyde ayırt edici özellikler elde etmesini sağlar.

(Ouyang vd., 2018)' de, yeniden yapılandırma ve ayırt edici kayıp fonksiyonları ile birlikte eğitilen, evrişimli sinir ağına dayalı hiperspektral görüntü sınıflandırma yöntemini önermiştir. Ağda, küçük evrişimli çekirdekler, özellik soyutlamasını gerçekleştirmek için havuzlama operatörü ile kademeli hale getirilir ve ters evrişimli ve paylaşımsız operatörlerden oluşan bir kod çözme kanalı kurulur. Kod çözme kanalı tarafından gerçekleştirilen denetimsiz yeniden yapılandırma, yalnızca ağ eğitimine öncelik vermekle kalmaz, aynı zamanda soyutlanmış özelliklerin kontrol kapısı tarafından ayırt edilebilirliğini artırmak için de kullanılır.

(F. Liu ve Q. Wang, 2020) ' de, HSI için seyrek tensöre dayalı bir sınıflandırma (STC) yöntemi önerilmektedir. Geleneksel vektör tabanlı veya matris tabanlı yöntemlerden farklı olarak STC, ortak uzaysal-spektral tensör özelliklerini çıkarmak için tensör tekniğini kullanır. Sınıf içi uzamsal-spektral varyasyonu hafifletmek ve aynı anda sınıflandırma performansını iyileştirmek için temel bileşen analizi (PCA) ve HSI'nin 3-D içsel uzamsal-spektral tensörlerinden yararlanıyoruz.

(Cao ve W. Guo, 2020)' de, HIC için yalnızca zengin özellikleri çıkarmakla kalmayıp aynı zamanda ağı daha da derinleştirmeyen, kademeli çift ölçekli bir geçiş ağı önermektedir. İki farklı kademeli çift ölçekli geçiş bloğunu sürekli olarak birbirine bağlar ve HSI'lerin spektral-uzamsal özelliklerini otomatik olarak çıkarır. Ayrıca, sınırlı eğitim örnekleri için, önerilen ağ, farklı spektral boyutlu ve uzamsal boyutlu evrişim çekirdekleri kullanarak daha ayırt edici bağlamsal özellikleri esnek bir şekilde yakalayabilir. Ayrıca, görüntülerin ilgi alanlarını elde etmek için görüntülerin bilgi akışını ve kontrastını iyileştirmek için iki farklı çapraz birleştirme yöntemi tasarlanmıştır. Aşırı uyumu azaltmak ve ağ eğitimini hızlandırmak için iki atlama yapısı da kullanılır.

(X. Ma vd., 2016)'de, uzamsal güncellenmiş derin otomatik kodlayıcı (SDAE) ve işbirliğine dayalı temsile dayalı bir sınıflandırmayı dağıtan bir spektral-uzamsal sınıflandırma yöntemi önerilmiştir. Algoritma 3 bölümden oluşur: özellik gösterimi, sınıflandırma ve uzamsal düzenleme. Özellik çıkarma adımında hem spektral hem de uzamsal özellikler elde edilir. Spektral özellikler çıkarılırken, her numune arasındaki korelasyon hesaplanır ve bu

benzerlik düzenleme terimi, otomatik kodlayıcının enerji fonksiyonuna eklenir. Böylelikle kodlama işlemi sırasında benzer örnekler arasındaki korelasyonun korunması amaçlanmıştır. Mekansal bilgiyi dikkate almak için gizli katmandan sonra bir güncelleme katmanı eklenir. Güncelleme katmanında, her bir özellik, çevreleyen örneklerden hesaplanan özelliklerin ağırlıklı ortalaması ile değiştirilir. Her örneğin ağırlığı, merkezden Öklid mesafesine göre üssel olarak değişir. Tüm katmanları önceden eğittikten sonra, eğitimi denetlemek için çıktı katmanına çok terimli lojistik regresyon (MLR) eklenir. Sınıflandırma adımında işbirlikçi temsile dayalı sınıflandırma uygulanır. Burada, her test örneğinin özellikleri, eğitim özelliklerinin doğrusal kombinasyonları olarak açıklanmaktadır. Klasik seyrek gösterime dayalı bir sınıflandırma kullanılarak, her bir test numunesinin sınıf etiketi belirlenir. Çerçeve, numuneler sınırlı olduğunda başarılı olacak şekilde tasarlanmıştır, bu nedenle deneyler küçük eğitim setleriyle gerçekleştirilir.

(Y. Li vd., 2017)' de, hyperspektral verilerde bulunan hem spektral hem de uzamsal bilgiden tam olarak yararlanan bir 3D-CNN çerçevesi önerilmektedir. herhangi bir ön işleme ve son işleme operasyonu olmadan, yöntem, giriş görüntüsüne doğrudan 3B çekirdekleri uygular. Mimari 2 evrimsel katmandan ve tamamen bağlantılı bir katmandan oluşur, havuzlama işlemi uygulanmaz. Çekirdeklerin boyutu deneylerle belirlenir.

(Sellami vd., 2019)'de, uyarlanabilir boyut azaltma (ADR) ve hiper-spektral görüntülerin (HSI) spektro-uzamsal sınıflandırması için yarı denetimli 3-D evrimsel sinir ağına (3-D CNN) dayalı yeni bir yaklaşım önermektedir. En alakalı spektral bantları seçerek boyutluluk laneti ve sınırlı sayıda eğitim örneği sorununu çözer. Seçilen gruplar bilgilendirici, ayrımcı ve ayırt edici olmalıdır. Yarı denetimli bir 3-D CNN özellik çıkarıcıya beslenirler, ardından sınıflandırma haritasını oluşturmak için bir doğrusal regresyon sınıflandırıcıya beslenirler. Aslında, önerilen yarı denetimli 3-D CNN modeli, HSI sınıflandırmasını geliştirmek için evrimsel kodlayıcı-kod çözücüye dayalı derin spektral ve uzamsal özellikleri çıkarmayı amaçlamaktadır. Bu özellikleri seçilen ilgili bantlardan çıkarmak için birkaç 3-D evrim ve maksimum havuz katmanı kullanır. Önerilen yaklaşımın temel avantajı, HSI'nin yüksek boyutluluğunu azaltmaktır, ilgili spektro-uzamsal bilgileri koruyun ve birkaç etiketli eğitim örneği kullanarak sınıflandırmayı geliştirin. hyperspektral görüntülerin (HSI'ler) spektro-uzamsal sınıflandırması için yarı denetimli 3-D evrimsel sinir ağı (3-D CNN). yarı denetimli bir 3-D CNN özellik çıkarıcıya beslenir, ardından sınıflandırma haritasını oluşturmak için doğrusal bir regresyon sınıflandırıcıya beslenir. Aslında, önerilen yarı denetimli 3-D CNN

modeli, HSI sınıflandırmasını geliştirmek için evrişimli kodlayıcı-kod çözücüye dayalı derin spektral ve uzamsal özellikleri çıkarmayı amaçlamaktadır. Bu özellikleri seçilen ilgili bantlardan çıkarmak için birkaç 3-D evrişim ve maksimum havuz katmanı kullanır. Önerilen yaklaşımın temel avantajı, HSI'nin yüksek boyutluluğunu azaltmak, ilgili spektro-uzaysal bilgileri korumak ve birkaç etiketli eğitim örneği kullanarak sınıflandırmayı geliştirmektir.

(Xing vd., 2016)' de, denetlenmemiş eğitimin yığılmış denoising otomatik kodlayıcılar ve lojistik regresyon (LR) yoluyla denetimli ince ayar yoluyla elde edildiği durumlarda, SDAE tabanlı derin bir yöntem önerilmektedir. ReLU, özelliklerin ayrılabilirliğini artırdığı için aktivasyon fonksiyonu olarak seçilmiştir. Her DAE katmanı bağımsız olarak eğitilir ve kod çözme katmanları eğitimden sonra kaldırılır. Çıktı katmanına lojistik regresyon eklenir sınıflandırma için. Makalede hiperspektral görüntünün uzamsal bilgisinden yararlanılmamıştır. Deneylerde üç veri kümesi kullanılmıştır: Indian Pines, Botsvana ve Pavia Üniversitesi. Üç ağ parametresi, katman sayısı, her katmandaki birim sayısı ve Gauss gürültüsünün standart sapması, doğrulama verileri üzerindeki optimal sınıflandırma sonuçları. Algoritmanın hesaplama süresi, doğrusal çekirdekli SVM ve RBF çekirdekli SVM yöntemleriyle karşılaştırılır. Önerilen yöntemin RBF çekirdekli SVM'den çok daha hızlı ve doğrusal çekirdekli SVM'den biraz daha yavaş olduğu görülmüştür.

(Deng vd., 2019)'de , hem aynı hem de sahneler arası HSI sınıflandırmaları için görevleri karşılayabilen derin metrik öğrenmeye dayalı bir özellik yerleştirme modeli öneriyoruz. İlk görevde, yalnızca birkaç etiketli örnek mevcut olduğunda, derin gömme özelliklerine dayalı metrik öğrenmeden elde edilen fikirleri kullanırız ve örnek çiftleri arasında bir benzerlik öğrenimi yaparız. Bu durumda, önerilen model iki örneğin aynı sınıfa ait olup olmadığını karşılaştırmayı iyi öğrenebilir. Başka bir görevde, sınıflandırılması gereken bir HSI görüntüsü (hedef sahne) hiç etiketlenmediğinde, gömme modeli yeterli etiketli örneklerle başka bir benzer HSI görüntüsünden (kaynak sahne) öğrenebilir ve ardından kullanarak hedef modele aktarabilir. yalnızca kaynak ve hedef örneklerden gömme özelliklerini ayırt edilemez hale getirmek için rakip yaklaşımı kullanan değil, aynı zamanda hedef sahnenin yerleştirmelerini kaynak sahne biriyle benzer kümeler oluşturmaya teşvik eden denetimsiz bir alan uyarlama tekniği. İki sahnenin HSI'leri arasındaki alan uyarlaması tamamlandıktan sonra, herhangi bir geleneksel HSI sınıflandırıcı kullanılabilir. Basit bir şekilde, bu makale boyunca sınıflandırma görevleri için sınıflandırıcı olarak en yakın komşu (NN) algoritması seçilmiştir.

(Zhou vd., 2019)' de, HSI sınıflandırması için yeni bir DL çerçevesi, yani yardımcı

eđitimli yarı denetimli yıđınlanmış otomatik kodlayıcılar (Yarı SAE'ler) sunuyoruz. İlk olarak, sırasıyla hiperspektral özelliklere ve uzamsal özelliklere dayalı olarak iki SAE önce-den eđitilir. İkinci olarak, iki SAE için alternatif olarak yarı denetimli bir eş eđitim şeklinde ince ayar yapılır, burada ilk eđitim seti etkili bir bölge büyütme yöntemi tasarlanarak büyütölür. Son olarak, iki SAE tarafından elde edilen sınıflandırma olasılıkları, yinelenen koşullu modlarla çözülen bir Markov rastgele alan modeli kullanılarak birleştirilir.

(Kamilaris ve Prenafeta-Boldú, 2018)



Tablo 2.2: Pavia Üniversitesi için sonuçlar

İndeks	Yöntem	Eğitim Seti	OA(%)	AA(%)	Kappa
(Zhao, Z. Guo, vd., 2015)	ESA	3921	96.37	95.06	0.95
(Y. Liu vd., 2015)	SdA	42.776 (%10)	96.7	95.4	0.95
(Yue, Zhao, vd., 2015)	DCNNs	3921	95.18	93.51	0.9364
(Zhao ve Du, 2016)	SSFC	450 + 2700	96.98	-	-
(Yue, Mao, vd., 2016)	SAE-DCNNs	3921	96.28	96.31	0.9511
(A. J. Guo ve Zhu, 2018)	ANNC-SCC	1800	93.60	93.68	0.9145
(Chen vd., 2018)	ESA-SVM	Her class %20	98.44	-	-
(Zhong vd., 2017)	SSRN	4281 ->train 4281 ->val	99.79	99.66	0.9972
(Paoletti vd., 2018)	ESA	Her class 200 tane (27x27)	97.80	98.29	0.9709
(Roy vd., 2019)	3B-2B-ESA	%20 (25x25x15)	99.98	99.98	0.9997
(Bai vd., 2019)	SSDC-DenseNet	%5 train %15 val	99.84	99.72	0.9979
(S. Li vd., 2019)	ASSFL	4278	99.88	99.54	0.9971
(Mirzaei, Khosravani, vd., 2019)	BCP-3B-ESA	Her class %20	97.53	97.65	-
(Jiang vd., 2019)	3B-SRNet	3930	99.92	99.94	0.9990
(Q. Gao ve Lim, 2019)	pbCNN+DPR	Her class 200 tane	99.26	99.16	0.9902
(C. Wang vd., 2019)	3D-CNN-JM	8558	99.42	99.29	0.9927
(H. Gao vd., 2019)	PRAN	train 4273 val 4273	99.92	99.87	0.9990
(Ouyang vd., 2018)	CNN-JL-G	Her class 100 tane	97.19	97.42	0.9627
(He vd., 2019)	HSI-BERT	Her class 200 tane	99.75	99.86	-
(F. Liu ve Q. Wang, 2020)	STC	Her class 200 tane	98.50	98.34	0.9798
(Cao ve W. Guo, 2020)	CDSCN	train 4281 val 4281 (7x7)	99.84	99.79	0.9872

Tablo 2.3: India Pines için sonuçlar

İndeks	Yöntem	Eğitim Seti	OA(%)	AA(%)	Kappa
(X. Ma vd., 2016)	SDAE-CR	Her class %10	99.22	98.54	0.9911
(Chen vd., 2018)	ESA-SVM	Her class %20	98.39	-	-
(Zhong vd., 2017)	SSRN	2055 ->train 1024 ->val	99.19	98.93	0.9907
(Paoletti vd., 2018)	ESA	2466 (29x29)	98.37	99.27	0.9815
(Roy vd., 2019)	3B-2B-ESA	%30 (25x25x30)	99.75	99.71	0.9963
(Bai vd., 2019)	SSDC-DenseNet	%15 train %10 val	99.53	99.41	0.9947
(S. Li vd., 2019)	ASSFL	1024	98.18	97.80	0.9789
(Mirzaei, Khosravani, vd., 2019)	BCP-3B-ESA	Her class %10	98.33	98.72	0.9810
(Jiang vd., 2019)	3B-SRNet	1765	98.88	99.38	0.9869
(Q. Gao ve Lim, 2019)	pbCNN+MRF	2215	97.98	98.10	0.9742
(C. Wang vd., 2019)	3D-CNN-JM	2055	98.90	98.91	0.9862
(H. Gao vd., 2019)	PRAN	train 2045 val 1018	99.67	99.37	0.9962
(Ouyang vd., 2018)	CNN-JL-G	1342	95.48	96.04	0.9477
(He vd., 2019)	HSI-BERT	1600 (8 class)	99.56	99.72	-
(F. Liu ve Q. Wang, 2020)	STC	1550	97.53	97.60	0.9716
(Cao ve W. Guo, 2020)	CDSC	train 2055 val 1025 (7x7)	99.62	99.57	0.9951

Tablo 2.4: Saliens için sonuçlar

İndeks	Yöntem	Eğitim Seti	OA(%)	AA(%)	Kappa
(A. J. Guo ve Zhu, 2018)	ANNC-SCC	3200	93.12	97.12	0.9230
(Roy vd., 2019)	3B-2B-ESA	%30 (25x25x15)	100	100	1
(Bai vd., 2019)	SSDC-DenseNet	%5 train %15 val	99.73	99.81	0.997
(S. Li vd., 2019)	ASSFL	5415	99.91	99.87	0.9968
(Mirzaei, Khosravani, vd., 2019)	BCP-3B-ESA	Her class %20	99.76	99.57	-
(Q. Gao ve Lim, 2019)	pbCNN+DPR	Her class 200 tane	98.14	99.15	0.9792
(H. Gao vd., 2019)	PRAN	train 5403 val 5403	99.90	99.93	0.99.89
(He vd., 2019)	HSI-BERT	Her class 200 tane	99.56	99.84	-

### 3. Kaynaklar

1. Bai, Yutong, Zhang, Qifan, Lu, Zexin, ve Zhang, Yi (2019). “SSDC-DenseNet: A Cost-Effective End-to-End Spectral-Spatial Dual-Channel Dense Network for Hyperspectral Image Classification”. In: IEEE Access 7, pages 84876–84889.
2. Cao, Feilong ve Guo, Wenhui (2020). “Cascaded dual-scale crossover network for hyperspectral image classification”. In: Knowledge-Based Systems 189, page 105122.
3. Chen, Congcong vd. (2018). “Hyperspectral classification based on spectral-spatial convolutional neural networks”. In: Engineering Applications of Artificial Intelligence 68, pages 165–171.
4. Ciresan, Dan Claudiu, Meier, Ueli, Gambardella, Luca Maria, ve Schmidhuber, Jurgen (2011). “Convolutional neural network committees for handwritten character classification”. In: 2011 International Conference on Document Analysis and Recognition. IEEE, pages 1135–1139.
5. Deng, Bin, Jia, Sen, ve Shi, Daming (2019). “Deep metric learning-based feature embedding for hyperspectral image classification”. In: IEEE Transactions on Geoscience and Remote Sensing 58.2, pages 1422–1435.
6. Eismann, MT (2012). “Hyperspectral Remote Sensing, 458 SPIE Press”. In: Bellingham, Washington DC.
7. Farabet, Clement, Couprie, Camille, Najman, Laurent, ve LeCun, Yann (2012). “Learning hierarchical features for scene labeling”. In: IEEE transactions on pattern analysis and machine intelligence 35.8, pages 1915–1929.
8. Fischer, Christian ve Kakoulli, Ioanna (2006). “Multispectral and hyperspectral imaging technologies in conservation: current research and potential applications”. In: Studies in Conservation 51.sup1, pages 3–16.
9. Gao, Hongmin, Yang, Yao, Yao, Dan, ve Li, Chenming (2019). “Hyperspectral image classification with pre-activation residual attention network”. In: IEEE Access 7, pages 176587–176599.
10. Gao, Qishuo ve Lim, Samsung (2019). “Classification of hyperspectral images with convolutional neural networks and probabilistic relaxation”. In: Computer Vision and Image Understanding 188, page 102801.
11. Goetz, Alexander FH, Vane, Gregg, Solomon, Jerry E, ve Rock, Barrett N (1985). “Imaging spectrometry for earth remote sensing”. In: science 228.4704, pages 1147–1153.
12. Guo, Alan JX ve Zhu, Fei (2018). “Spectral-spatial feature extraction and classification by ANN supervised with center loss in hyperspectral imagery”. In: IEEE Transactions on Geoscience and Remote Sensing 57.3, pages 1755–1767.
13. He, Ji, Zhao, Lina, Yang, Hongwei, Zhang, Mengmeng, ve Li, Wei (2019). “HSI-BERT: Hyperspectral Image Classification Using the Bidirectional Encoder Representation From Transformers”. In: IEEE Transactions on Geoscience and Remote Sensing 58.1, pages 165–178.
14. Hu, Wei, Huang, Yangyu, Wei, Li, Zhang, Fan, ve Li, Hengchao (2015). “Deep convolutional neural networks for hyperspectral image classification”. In: Journal of Sensors 2015.

15. Jiang, Yenan, Li, Ying, ve Zhang, Haokui (2019). “Hyperspectral image classification based on 3-D separable ResNet and transfer learning”. In: IEEE Geoscience and Remote Sensing Letters 16.12, pages 1949–1953.
16. Kalchbrenner, Nal, Grefenstette, Edward, ve Blunsom, Phil (2014). “A convolutional neural network for modelling sentences”. In: arXiv preprint arXiv:1404.2188.
17. Kamilaris, Andreas ve Prenafeta-Boldú, Francesc X (2018). “Deep learning in agriculture: A survey”. In: Computers and electronics in agriculture 147, pages 70–90.
18. Khan, Muhammad Jaleed, Khan, Hamid Saeed, Yousaf, Adeel, Khurshid, Khurram, ve Abbas, Asad (2018). “Modern trends in hyperspectral image analysis: A review”. In: IEEE Access 6, pages 14118–14129.
19. Lawrence, Steve, Giles, C Lee, Tsoi, Ah Chung, ve Back, Andrew D (1997). “Face recognition: A convolutional neural-network approach”. In: IEEE transactions on neural networks 8.1, pages 98–113.
20. LeCun, Yann, Haffner, Patrick, Bottou, Léon, ve Bengio, Yoshua (1999). “Object recognition with gradient-based learning”. In: Shape, contour and grouping in computer vision. Springer, pages 319–345.
21. Li, Simin, Zhu, Xueyu, Liu, Yang, ve Bao, Jie (2019). “Adaptive spatial-spectral feature learning for hyperspectral image classification”. In: IEEE Access 7, pages 61534–61547.
22. Li, Ying, Zhang, Haokui, ve Shen, Qiang (2017). “Spectral–spatial classification of hyperspectral imagery with 3D convolutional neural network”. In: Remote Sensing 9.1, page 67.
23. Liu, Fengshuang ve Wang, Qiang (2020). “A sparse tensor-based classification method of hyperspectral image”. In: Signal Processing 168, page 107361.
24. Liu, Yazhou, Cao, Guo, Sun, Quansen, ve Siegel, Mel (2015). “Hyperspectral classification via deep networks and superpixel segmentation”. In: International Journal of Remote Sensing 36.13, pages 3459–3482.
25. Lowe, Amy, Harrison, Nicola, ve French, Andrew P (2017). “Hyperspectral image analysis techniques for the detection and classification of the early onset of plant disease and stress”. In: Plant methods 13.1, pages 1–12.
26. Lu, Guolan ve Fei, Baowei (2014). “Medical hyperspectral imaging: a review”. In: Journal of biomedical optics 19.1, page 010901.
27. Ma, Li, Crawford, Melba M, ve Tian, Jinwen (2010). “Local manifold learning-based  $k$ -nearest-neighbor for hyperspectral image classification”. In: IEEE Transactions on Geoscience and Remote Sensing 48.11, pages 4099–4109.
28. Ma, Xiaorui, Wang, Hongyu, ve Geng, Jie (2016). “Spectral–spatial classification of hyperspectral image based on deep auto-encoder”. In: IEEE Journal of Selected Topics in Applied Earth Observations and Remote Sensing 9.9, pages 4073–4085.
29. Mirzaei, Sayeh, Khosravani, Shima, vd. (2019). “Hyperspectral image classification using non-negative tensor factorization and 3D convolutional neural networks”. In: Signal Processing: Image Communication 76, pages 178–185.
30. Ouyang, Ning, Zhu, Ting, ve Lin, Leping (2018). “Convolutional neural network trained by joint loss for hyperspectral image classification”. In: IEEE Geoscience and Remote Sensing Letters 16.3, pages 457–461.
31. Paoletti, Mercedes E, Haut, Juan Mario, Plaza, Javier, ve Plaza, Antonio (2018). “A new deep convolutional neural network for fast hyperspectral image classification”. In: ISPRS journal of photogrammetry and remote sensing 145, pages 120–147.

32. Read, J.M. ve Torrado, M. (2009). “Remote Sensing”. In: *International Encyclopedia of Human Geography*. Edited by Rob Kitchin ve Nigel Thrift. Oxford: Elsevier, pages 335–346. ISBN: 978-0-08-044910-4.
33. Roy, Swalpa Kumar, Krishna, Gopal, Dubey, Shiv Ram, ve Chaudhuri, Bidyut B (2019). “HybridSN: Exploring 3-D–2-D CNN feature hierarchy for hyperspectral image classification”. In: *IEEE Geoscience and Remote Sensing Letters* 17.2, pages 277–281.
34. Sellami, Akrem, Farah, Mohamed, Farah, Imed Riadh, ve Solaiman, Basel (2019). “Hyperspectral imagery classification based on semi-supervised 3-D deep neural network and adaptive band selection”. In: *Expert Systems with Applications* 129, pages 246–259.
35. Sermanet, Pierre, Chintala, Soumith, ve LeCun, Yann (2012). “Convolutional neural networks applied to house numbers digit classification”. In: *Proceedings of the 21st International Conference on Pattern Recognition (ICPR2012)*. IEEE, pages 3288–3291.
36. Shippert, Peg (2003). “Introduction to hyperspectral image analysis”. In: *Online Journal of Space Communication* 3.2003, page 13.
37. Sun, Da-Wen (2010). *Hyperspectral imaging for food quality analysis and control*. Elsevier.
38. Wang, Chunxing, Ma, Nan, Ming, Yanfang, Wang, Quan, ve Xia, Jinfeng (2019). “Classification of hyperspectral imagery with a 3D convolutional neural network and JM distance”. In: *Advances in Space Research* 64.4, pages 886–899.
39. Xing, Chen, Ma, Li, ve Yang, Xiaoquan (2016). “Stacked denoise autoencoder based feature extraction and classification for hyperspectral images”. In: *Journal of Sensors* 2016.
40. Yue, Jun, Mao, Shanjun, ve Li, Mei (2016). “A deep learning framework for hyperspectral image classification using spatial pyramid pooling”. In: *Remote Sensing Letters* 7.9, pages 875–884.
41. Yue, Jun, Zhao, Wenzhi, Mao, Shanjun, ve Liu, Hui (2015). “Spectral–spatial classification of hyperspectral images using deep convolutional neural networks”. In: *Remote Sensing Letters* 6.6, pages 468–477.
42. Zhao, Wenzhi ve Du, Shihong (2016). “Spectral–spatial feature extraction for hyperspectral image classification: A dimension reduction and deep learning approach”. In: *IEEE Transactions on Geoscience and Remote Sensing* 54.8, pages 4544–4554.
43. Zhao, Wenzhi, Guo, Zhou, Yue, Jun, Zhang, Xiuyuan, ve Luo, Liqun (2015). “On combining multiscale deep learning features for the classification of hyperspectral remote sensing imagery”. In: *International Journal of Remote Sensing* 36.13, pages 3368–3379.
44. Zhong, Zilong, Li, Jonathan, Luo, Zhiming, ve Chapman, Michael (2017). “Spectral–spatial residual network for hyperspectral image classification: A 3-D deep learning framework”. In: *IEEE Transactions on Geoscience and Remote Sensing* 56.2, pages 847–858.
45. Zhou, Shaoguang, Xue, Zhaohui, ve Du, Peijun (2019). “Semisupervised stacked autoencoder with cotraining for hyperspectral image classification”. In: *IEEE Transactions on Geoscience and Remote Sensing* 57.6, pages 3813–3826.